

Weekly Report

任务回顾

任务	状态
初始版本 + 3 大数据集 (MuSiQue / 2WikiMultiHop / HotpotQA)	✓
InfoNCE 对比学习训练框架	✓
IRCOT 风格评估流程	✓
所有多跳数据集评估跑通	☐ 进行中
创新点示意图完善	☐ 进行中
替换 EverMemOS Agentic Search 核心模块	🕒 计划中
论文整理 (目标 ICLR 2027)	🕒 计划中

当前进展

1. 实验策略调整：多跳数据集评估暂时降级

当前判断


本周对原始多跳 QA 数据集评估的推进策略做了重新判断。原因很直接：原始 MultiHop QA 评估的候选集合规模过大，例如 HotpotQA 的候选规模达到 8.8 million，在当前算力资源下，继续完整推进这条线的成本偏高，且短期内对系统落地的帮助有限。

调整后的结论

因此，这部分工作本周没有被定义为当前最高优先级。它的作用仍然存在，但更偏向论文中的方法对比、逻辑补强和后续实验完整性，而不是这一阶段最关键的交付项。换句话说，这条线并不是被否定，而是被后移。当前更高优先级的工作，是直接将新的 embedding model 融合进入 EverMemOS 的结构中，先验证系统路径是否跑通、替换是否成立、收益是否稳定。

2. 创新点示意图完善（初稿）

本周已完成创新点示意图的初稿整理。



3. 系统主路径推进：EverMemOS 核心 embedding 模块从 Deepinfra 切换到 vLLM

替换背景

本周另一个核心推进，是明确 EverMemOS 中 Agentic Search 的 embedding 模块替换方向：由 Deepinfra 切换为 vLLM。

当前 Deepinfra 方案的问题

现有 Deepinfra 方案本质上是通过 API 与云端模型交互，将端侧 memcell 内容发送到云端，再由云端返回 embedding 结果。这种设计在早期验证阶段是方便的，但随着系统逐步走向端侧部署，它的问题已经比较明确：

问题	影响
API 传输存在额外延迟和网络开销	不利于端侧场景下的响应效率
端侧 memcell 数据不能完全上云	存在隐私和安全限制
只能调用 Hugging Face 指定模型	无法灵活接入自研或微调后的 embedding 模型

这些问题和参考周报中对“记忆检索侧”的要求是直接冲突的。参考报告已经明确给出分层假设：检索侧模型需要轻量、快速、可端侧部署，同时在小模型上也要保证效果不明显掉队。沿着这个标准看，Deepinfra 更像是一个便于验证的中间方案，而不是最终适合长期保留的系统形态。

选择 vLLM 的原因

相较之下，vLLM 更符合当前阶段的系统目标。它支持本地部署 server 或本地模型交互，相当于直接在端侧完成 embedding 计算。这会带来三个直接收益：第一，避免网络传输造成的额外时延；第二，减少敏感 memcell 内容外发的风险；第三，支持接入自研或微调后的 embedding 模型，使后续方法迭代不再受限于第三方平台已支持的模型集合。

```
if provider.lower() == "vllm":
    config = VllmVectorizeConfig(
        api_key=api_key,
        base_url=base_url,
        model=model,
        timeout=timeout,
        max_retries=max_retries,
        batch_size=batch_size,
        max_concurrent_requests=max_concurrent,
        encoding_format=encoding_format,
        dimensions=dimensions,
    )
    return VllmVectorizeService(config)
elif provider.lower() == "deepinfra":
    config = DeepInfraVectorizeConfig(
        api_key=api_key,
        base_url=base_url,
        model=model,
        timeout=timeout,
        max_retries=max_retries,
        batch_size=batch_size,
        max_concurrent_requests=max_concurrent,
        encoding_format=encoding_format,
        dimensions=dimensions,
    )
    return DeepInfraVectorizeService(config)
else:
    raise VectorizeError(f"Unsupported provider: {provider}")
```

4. 检索推理：训练逻辑继续收紧

项目定位

当前主线的目标，仍然是围绕 LifeMem-AgenticSearch 构建一个更适合端侧部署的多跳检索推理框架，并逐步替换 EverMemOS 现有 Agentic Search 中成本高、耗时高、依赖云端的核心模块。

与此同时，训练逻辑也完成了一轮较重要的迭代，重点不是简单改动数据处理细节，而是更明确地控制模型在多跳检索训练中的学习偏置。当前主要做了四个调整：

调整项	本周处理	目的
样本顺序控制	显式保留部分不打乱顺序的 sample	in-batch 负样本采样时可以使用当前 trajectory 的 positive 作为强负例进行更深入的对比学习
Query / Document 标记	为 query 和 document 增加特殊符号	区分用户意图与召回内容

调整项	本周处理	目的
干扰建模	在构造下一步时显式考虑非 ground-truth retrieval doc 的干扰	让训练更接近真实多跳检索环境
候选位置随机化	Ground Truth Document 不再固定置于第一位，而是随机放入候选位置	降低模型对位置偏置的依赖

这一轮更新的共同目标，是把训练过程从“容易学到捷径的理想环境”，逐步拉向“更接近真实推理检索场景的受干扰环境”。

5. 下周重点

下周工作的重点，将继续围绕当前已经明确的系统主路径推进：

- 1. 继续完善创新点示意图，使其能够直接服务于论文中的方法表达。
- 2. 推进新的 embedding model 与 EverMemOS 的实际融合，优先完成系统侧接入验证。

Agentic search: BM25+ 4B embedding +4B reranker + generation

Agentic search: 0.6B Retrieval Embedding